Eksploracja Danych - projekt

Etap 1: Zrozumienie danych i problemu

Pokémon - Weedle's Cave

Alicja Sobiech, 188861
Nikolai Lavrinov, 201302
Maciej Łukasiewicz, 197865

20 kwietnia 2026

Spis treści

Sprawozdanie **2**
1. Cel eksploracji . . . 2
   1.1. Kryteria sukcesu . . . 2
2. Zbiór danych . . . 3
   2.1. Charakterystyka zbioru danych . . . 3
   2.2. Wstępne ustalenia dotyczące zawartości zbiorów . . . 3
   2.3. Opis atrybutów . . . 4
3. Eksploracyjna Analiza Danych . . . 5
   3.1. Uwagi na temat jakości danych . . . 5
   3.2. Wyniki eksploracyjnej analizy danych . . . 8
   3.3. Wyniki analizy danych a cel eksploracji . . . 17
4. Podsumowanie . . . 18
   4.1. Najważniejsze obserwacje . . . 18
   4.2. Wnioski końcowe . . . 18

Źródła **19**
Wykaz Literatury . . . 19

1. Cel eksploracji

Celem eksploracji jest budowa modelu pozwalającego na predykcję wyników walk pokemonów na podstawie przypisanym im statystyk. Docelowo rozwiązywanym problemem będzie **klasyfikacja binarna**. Dodatkowym celem jest określenie, które statystyki mają największy wpływ na rezultat pojedynków.

W przypadku tego problemu najistotniejszą metryką będzie dokładność [ang. *accuracy*], informująca nas o tym, jak dobrze nasz model klasyfikuje walki, bez względu na ich wynik. Dokładność opisana jest poniższym wzorem[4]:

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN}$$

gdzie:

- TP - [ang. *true positive*] ilość prawdziwie pozytywnych przypadków
  (w naszym przypadku: poprawnie przewidziane zwycięstwo pierwszego pokemona)
- TN - [ang. *true negative*] ilość prawdziwie negatywnych przypadków
  (w naszym przypadku: poprawnie przewidziane zwycięstwo drugiego pokemona)
- FP - [ang. *false positive*] ilość fałszywie pozytywnych przypadków
  (w naszym przypadku: błędnie przewidziane zwycięstwo pierwszego pokemona)
- FN - [ang. *false negative*] ilość fałszywie negatywnych przypadków
  (w naszym przypadku: błędnie przewidziane zwycięstwo drugiego pokemona)

Do oceny jakości modelu wykorzystujemy dodatkowo metrykę F1-score będącą średnią harmoniczną precyzji [ang. *precision*] i czułości [ang. *recall*]. Pozwala ona na bardziej zrównoważoną ocenę modelu, szczególnie gdy zależy nam na unikaniu zarówno błędów fałszywie pozytywnych jak i fałszywie negatywnych. F1-score wyznaczamy za pomocą poniższego wzoru[5]:

$$F_1 = \frac{2}{\text{recall}^{-1} + \text{precision}^{-1]}} = 2\frac{\text{precision} \cdot \text{recall}}{\text{precision} + \text{recall}} = \frac{2TP}{2TP + FP + FN}$$

gdzie:

- $\text{precision} = \frac{TP}{TP+FP}$ - odsetek prawdziwie pozytywnych przypadków spośród wszystkich uznanych przez model za pozytywne
- $\text{recall} = \frac{TP}{TP+FN}$ - odsetek przypadków prawdziwie pozytywnych spośród wszystkich rzeczywistych przypadków pozytywnych

1.1. Kryteria sukcesu

Sukces zostanie osiągnięty, jeżeli model uzyska dokładność [ang. *accuracy*] na poziomie 80%, a wartość miary F1-score na poziomie co najmniej 0.75.

2. Zbiór danych

Zbiór danych składa się z trzech zestawów danych charakteryzujących pokemony i rezultaty walk między nimi. Charakterystyka Pokémonów zebrana została z samej gry, ale rezultaty walk zostały wygenerowane w sposób nie biorący pod uwagę niektórych elementów prawdziwej gry.

Zbiory danych opisujące walki składają się z kolumn z numerami id walczących pokemonów. Zestaw `combats` zawiera dodatkowo wynik poszczególnych walk. Zbiór `tests` jest zbiorem testowym, zawierającym tylko numery id.

Zestaw danych `pokemon` zawiera numer id, nazwę oraz statystyki pokemona. W skład statystyk wchodzą rodzaje dwóch ataków, zdrowie (HP), generacja, informacja czy pokemon jest legendarny oraz 5 wartości numerycznych opisujących umiejętności każdego z pokemonów, takich jak np. siła ataku.

2.1. Charakterystyka zbioru danych

- **Pochodzenie**
  `https://www.kaggle.com/datasets/terminus7/pokemon-challenge`
- **Format**
  .csv
- **Zawarte zbiory danych**
  - Rozstrzygnięte walki - `combats.csv`
  - Pokémony - `pokemon.csv`
  - Zbiór testowy - `tests.csv`
- **Liczba przykładów**
  - `combats` - 50 000
  - `pokemon` - 800
  - `tests` - 10 000

2.2. Wstępne ustalenia dotyczące zawartości zbiorów

- Każdy przykład w zbiorze danych `combats` i `tests` opisuje jedną, niezależną od innych walkę między dwoma różnymi pokemonami.
- Statystyki pokemonów mają bezpośredni wpływ na wynik walk
- Brakujące wartości atrybutu `Type 2` oznaczają brak drugiego ataku a nie brak danych
- Zbiór danych `tests` służy tylko do oceny naszego modelu
- Kolejność pokemonów w zbiorach `combats` i `tests` nie powinna wpływać na wynik predykcji

2.3. Opis atrybutów

Tabela 2.1 opisuje wszystkie atrybuty zawarte w każdym z wykorzystanych zbiorów danych.

W ogólności atrybuty numeryczne dzielą się na dwie 'kategorie': numery identyfikacyjne i statystyki pokemonów. Wartości atrybutów reprezentujących statystyki nie odpowiadają żadnym jednostkom fizycznym - są one abstrakcyjne i uznajemy je za względne.

Tabela. 2.1: Opis atrybutów zawartych w zbiorach danych `combats`, `pokemon` i `tests`

Atrybut	**Typ**	**Znaczenie**
	`pokemon`	
#	Numeryczny	Numer identyfikujący danego pokemona
Name	Nominalny	Nazwa danego pokemona
Type 1	Nominalny	Typ pierwszego ataku. Typy pokemonów mają wpływ na efektywność wykonywanych ataków względem typu przeciwnika.
Type 2	Nominalny	Typ drugiego ataku (o ile jest wykonywany)
HP	Numeryczny	Punkty życia danego pokemona
Attack	Numeryczny	Siła regularnych ataków
Defense	Numeryczny	Siła regularnych ruchów obronnych
Sp. Atk	Numeryczny	Siła ataków specjalnych
Sp. Def	Numeryczny	Siła specjalnych ruchów obronnych
Speed	Numeryczny	Prędkość pokemona
Generation	Porządkowy	Atrybut informuje do jakiej generacji należy dany pokemon. W każdej kolejnej generacji dodawane są nowe pokemony, ruchy i zdolności.
Legendary	Nominalny	Atrybut informuje czy dany pokemon jest legendarny
	`combats`	
First_pokemon	Numeryczny	Numer identyfikujący pokemona rozpoczynającego dany pojedynek
Second_pokemon	Numeryczny	Numer identyfikujący pokemona atakującego w drugiej kolejności
Winner	Numeryczny	Numer identyfikujący pokemona, który wygrał dany pojedynek
	`tests`	
First_pokemon	Numeryczny	Numer identyfikujący pokemona rozpoczynającego dany pojedynek
Second_pokemon	Numeryczny	Numer identyfikujący pokemona atakującego w drugiej kolejności

3. Eksploracyjna Analiza Danych

3.1. Uwagi na temat jakości danych

Dane brakujące

Brakuje blisko połowy (386 na 800) wartości atrybutu `Type 2`.

Zakładamy, że drugi typ ataku jest opcjonalny a brak przypisanej wartości przyjmujemy jako brak drugiego typu. Nie uzupełniamy więc brakujących wartości poza zastąpieniem ich wartością "None".

Dane niespójne

Atrybuty nominalne nie zawierają błędów ortograficznych mających wpływ na analizę — każdy pokemon ma unikalną nazwę, więc ewentualne literówki nie wpływają na wyniki agregacji. Identyfikatory pokemonów w zbiorach `combats` i `tests` odwołują się wyłącznie do istniejących wpisów w zbiorze `pokemon`, co potwierdza spójność danych. Wartości numeryczne statystyk mieszczą się w rozsądnych zakresach i nie wykazują wewnętrznych sprzeczności.

Dane niezrozumiałe

Dane są na ogół zrozumiałe intuicyjnie, jednak pomocna jest podstawowa wiedza o mechanice gry Pokémon.

Atrybuty takie jak `Sp. Atk` i `Sp. Def` dotyczą ataków i obrony specjalnej, które w grze działają niezależnie od zwykłych statystyk ataku i obrony. Pojęcia generacji i statusu legendarnego wymagają kontekstu growego, lecz na potrzeby tej analizy ich interpretacja jest wystarczająco jasna.

Punkty oddalone

Średnia liczba punktów oddalonych względem atrybutów numerycznych wynosi ok. 9–10, co stanowi ok. 1,2% wszystkich danych. Atrybutami o największej liczbie punktów oddalonych są `HP` (19 punktów oddalonych: ok. 2,4% danych), `Defense` (13 punktów oddalonych: ok. 1,6% danych) oraz `Sp. Atk` (10 punktów oddalonych: ok. 1,2% danych).

Analizując punkty oddalone możemy dojść do wniosku, że dane są stosunkowo dobrej jakości - punkty te nie świadczą w naszym przypadku o błędach w danych.

Powyższe obserwacje zostały opracowane na podstawie tabeli 3.1 zaczynającej się na kolejnej stronie zaprezentowane są wykresy pudełkowe atrybutów numerycznych, będących statystykami pokemonów. Oprócz wykresów zaprezentowane są również wybrane wartości: Mediana (Med), Średnia wartość (Avg), PNW (Przedział najczęściej występujących wartości), Liczba punktów oddalonych (Odd) i Procentowej ilości punktów oddalonych na skali atrybutu (Odd(%))

Tabela. 3.1: Charakterystyka rozkładu wybranych atrybutów ze zbioru `pokemon`

Atrybut	**Wykres pudełkowy**	**Wartości**
HP	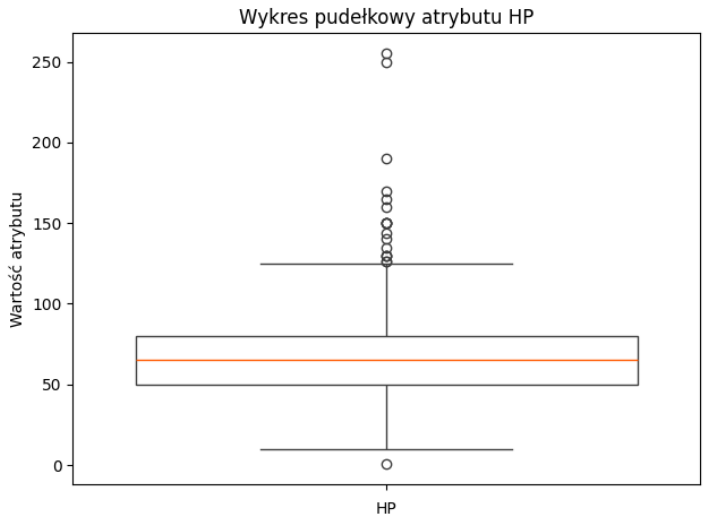	Med: 65.0 Avg: 69.26 PNW: [50.0; 80.0] Odd: 19 Odd(%): 2.38%
Attack	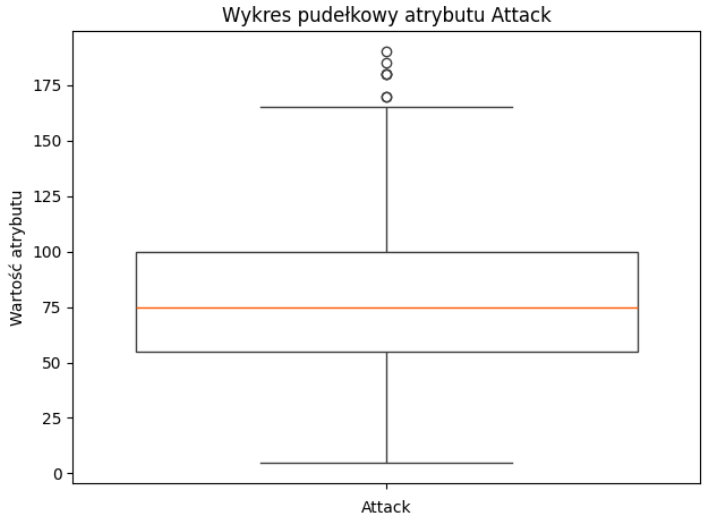	Med: 75.0 Avg: 79.0 PNW: [55.0; 100.0] Odd: 7 Odd(%): 0.88%
Defense	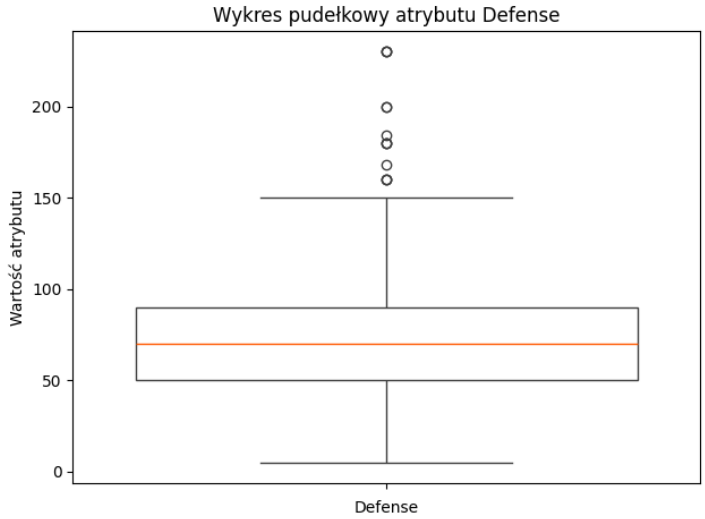	Med: 70.0 Avg: 73.84 PNW: [50.0; 90.0] Odd: 13 Odd(%): 1.62%

Atrybut	Wykres pudełkowy	Wartości
Sp. Atk	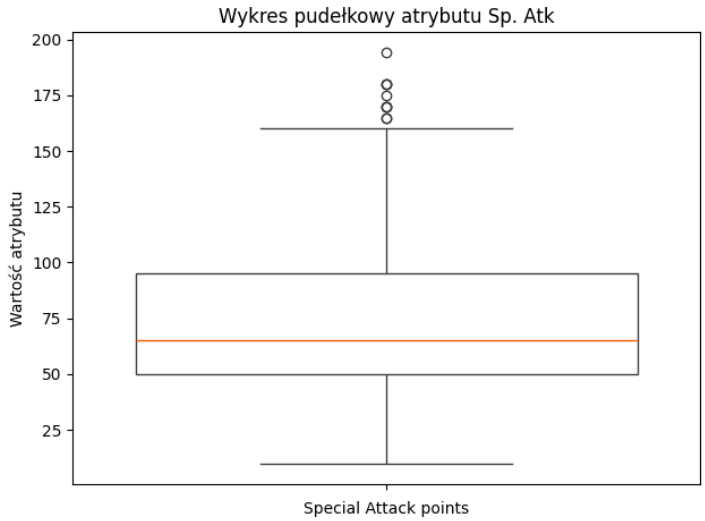	Med: 65.0 Avg: 72.82 PNW: [49.75; 95.0] Odd: 10 Odd(%): 1.25%
Sp. Def	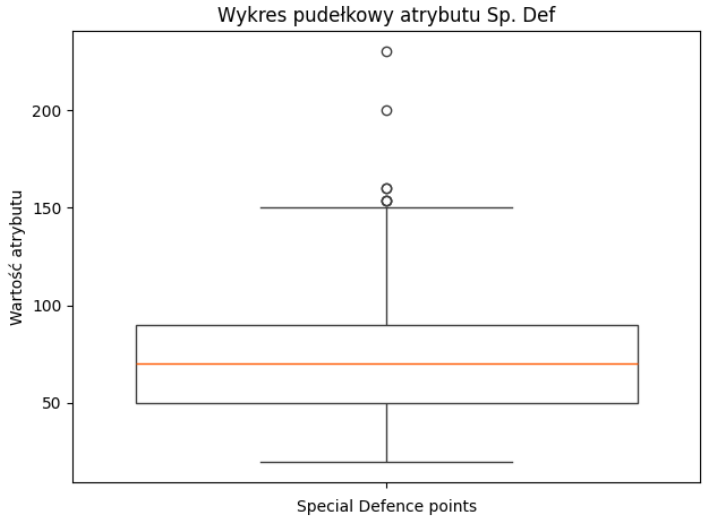	Med: 70 Avg: 71.90 PNW: [50.0; 90.0] Odd: 7 Odd(%): 0.88%
Speed	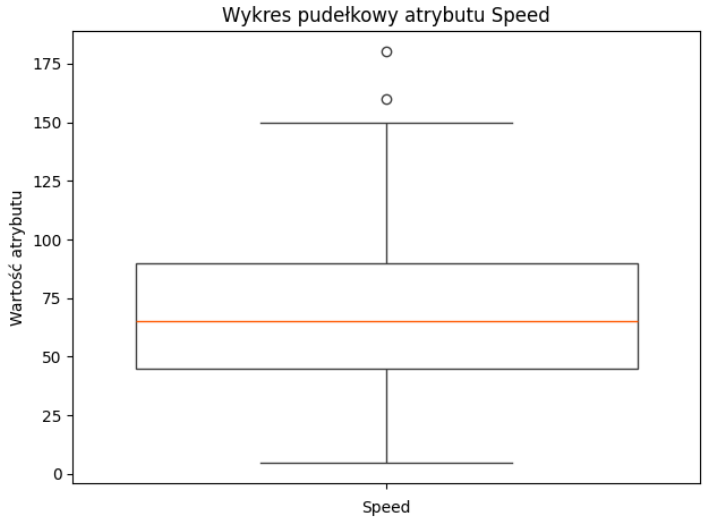	Med: 65.0 Avg: 68.28 PNW: [45.0; 90.0] Odd: 2 Odd(%): 0.25%

3.2. Wyniki eksploracyjnej analizy danych

Rozkłady wartości atrybutów

Tabela. 3.2: Rozkłady wartości wybranych atrybutów zbioru danych `pokemon`

Atrybut	Wykres
Legendary	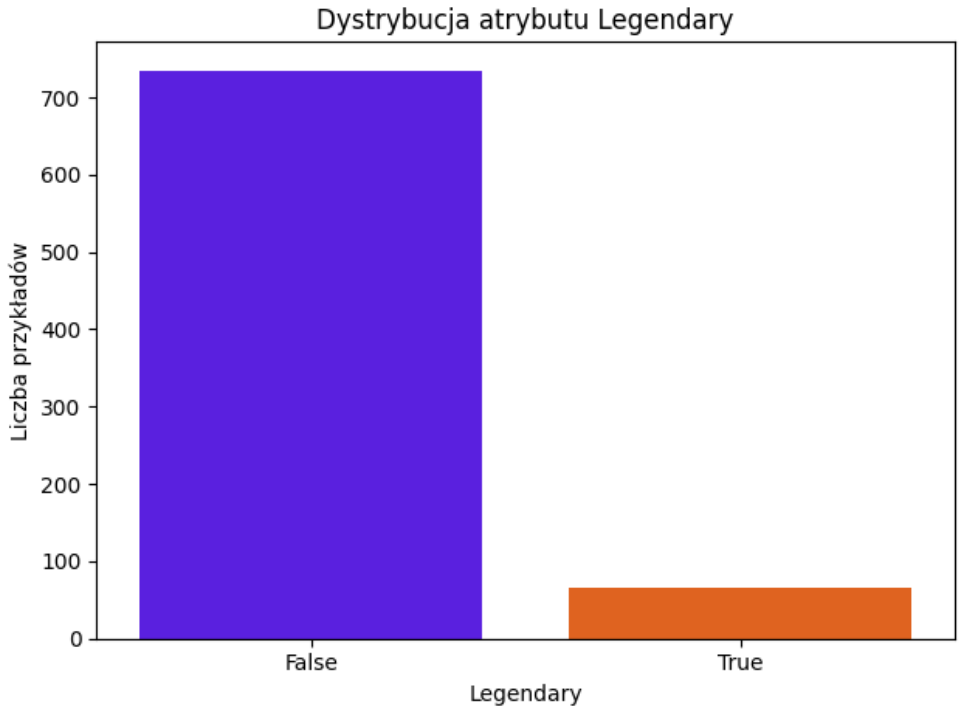
Generation	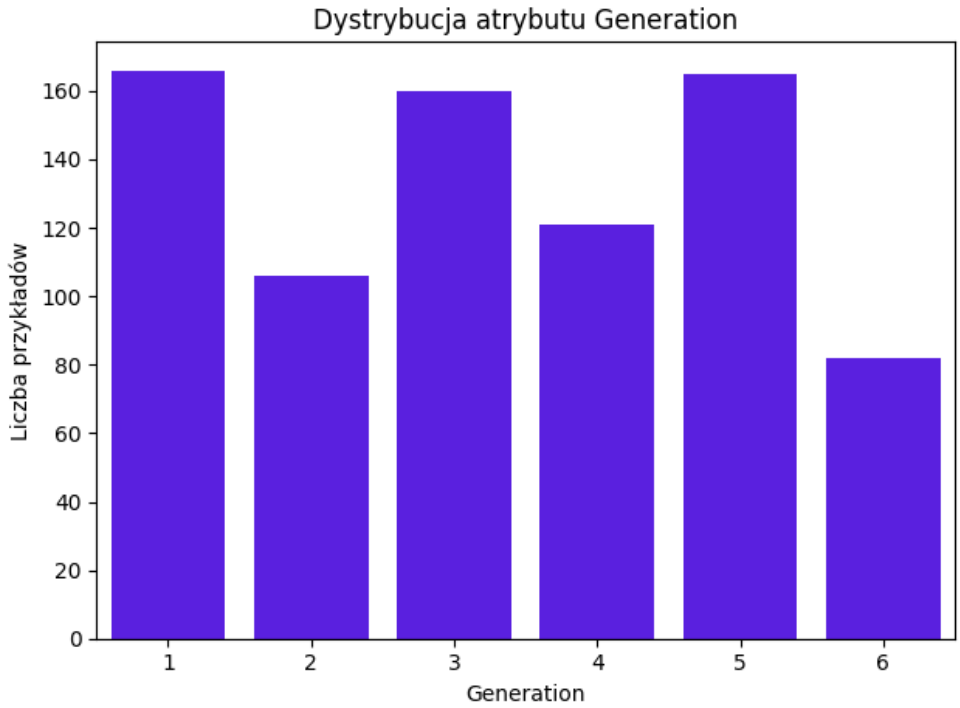

Atrybut	Wykres
Type 1	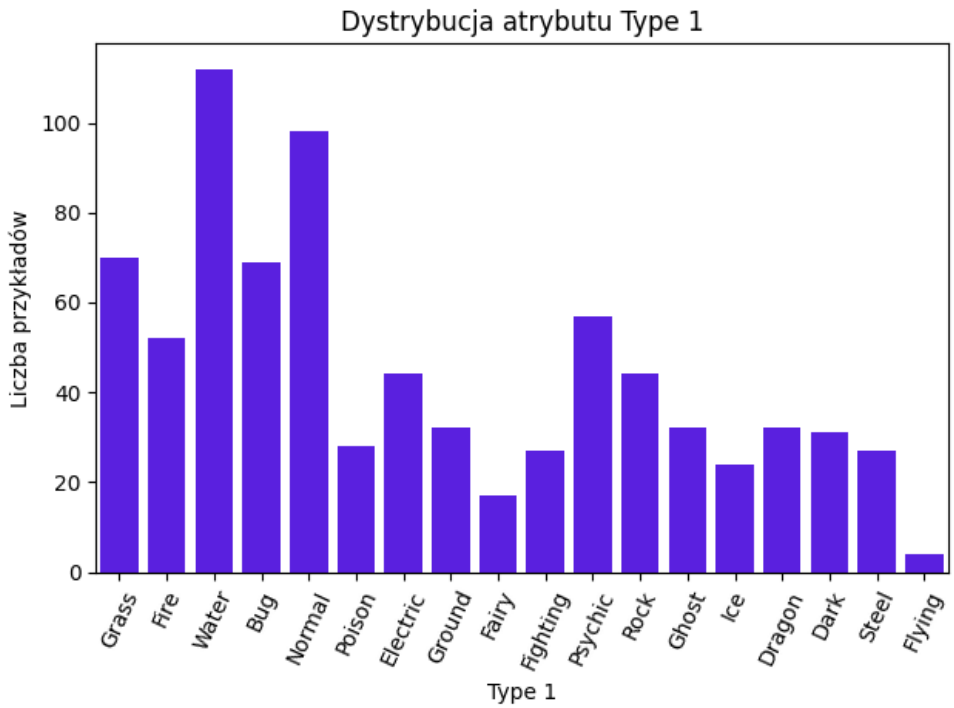
Type 2 (no missing values)	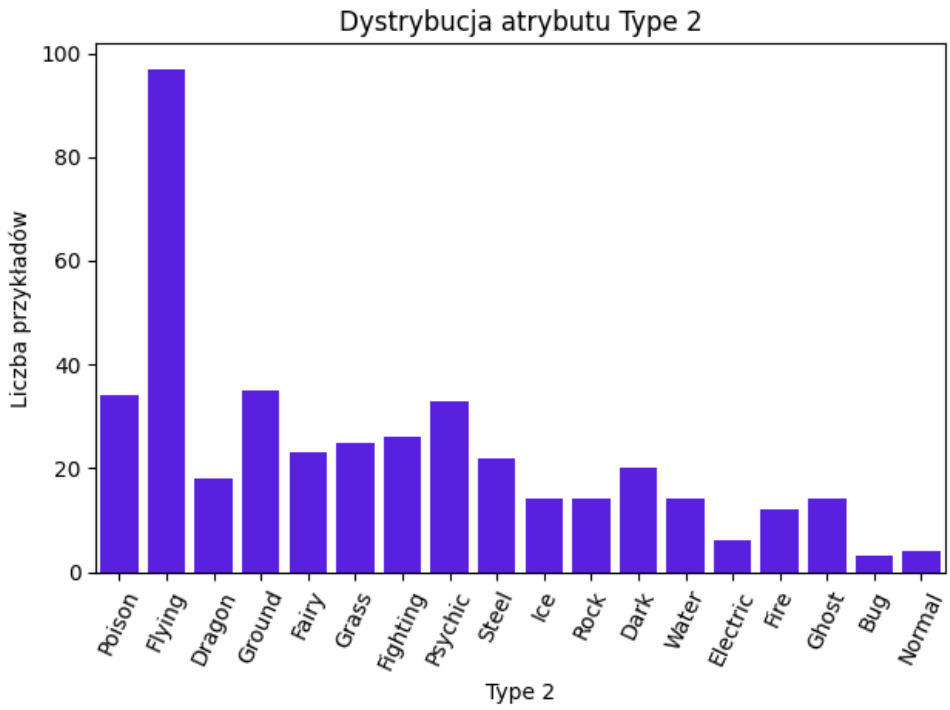

Atrybut	Wykres
Type 2 (with missing values)	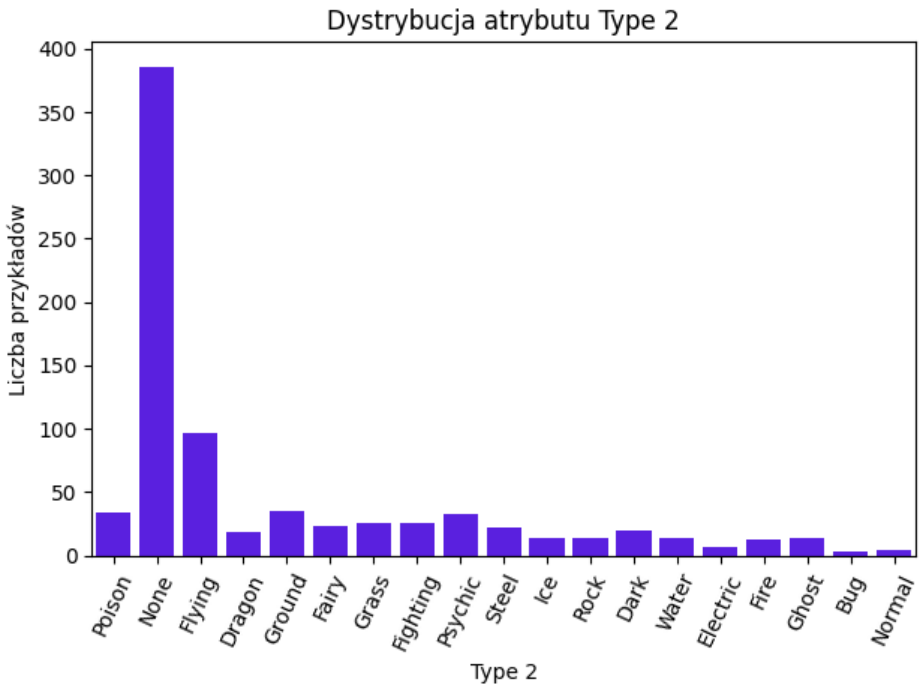
HP	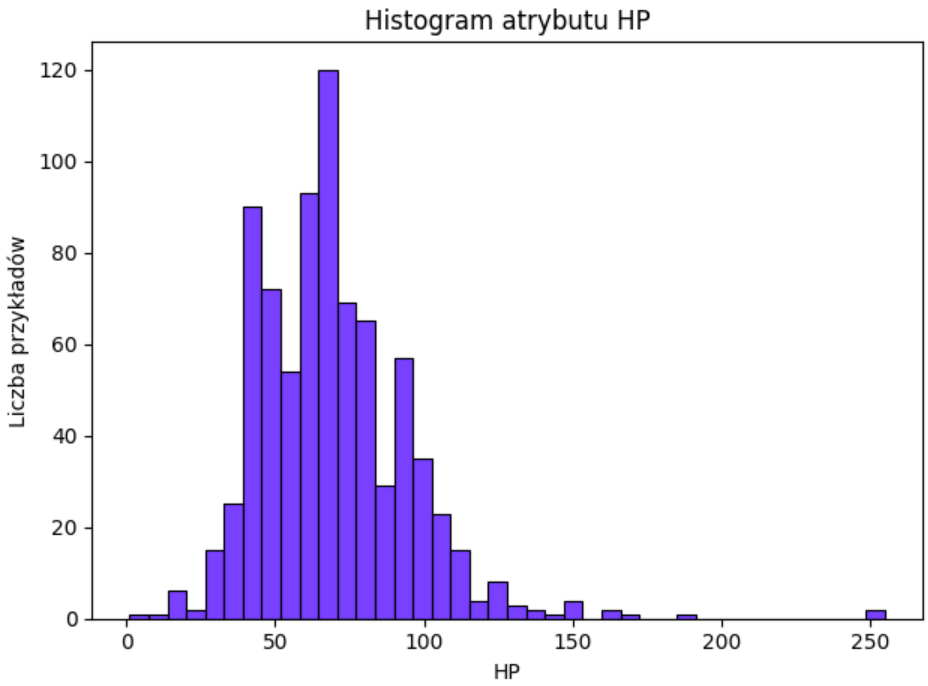

Atrybut	Wykres
Attack	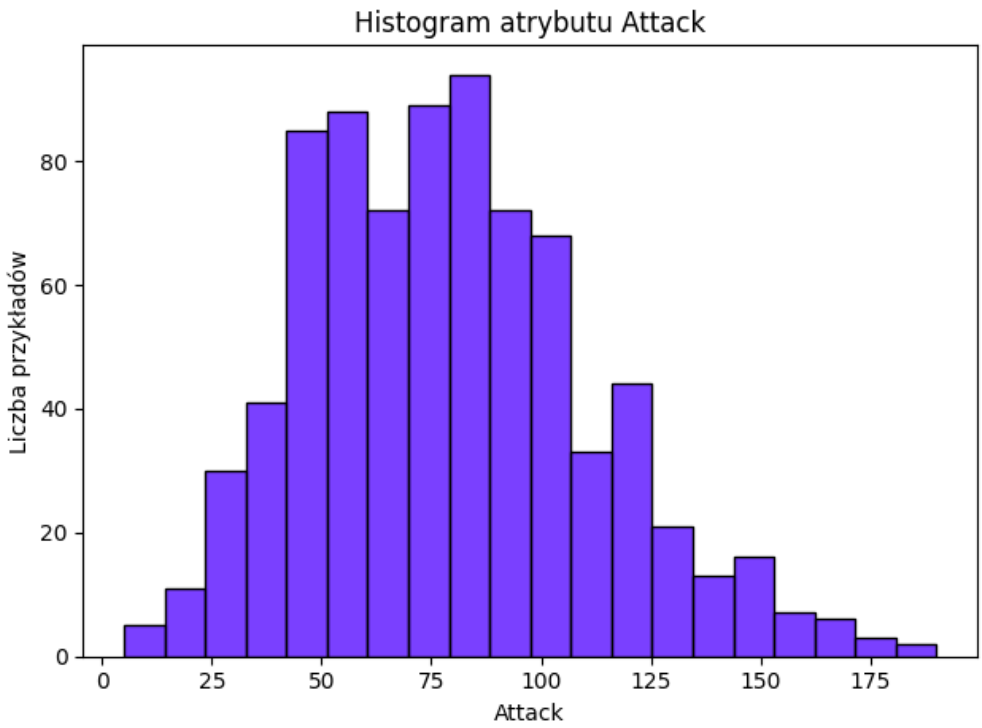
Defense	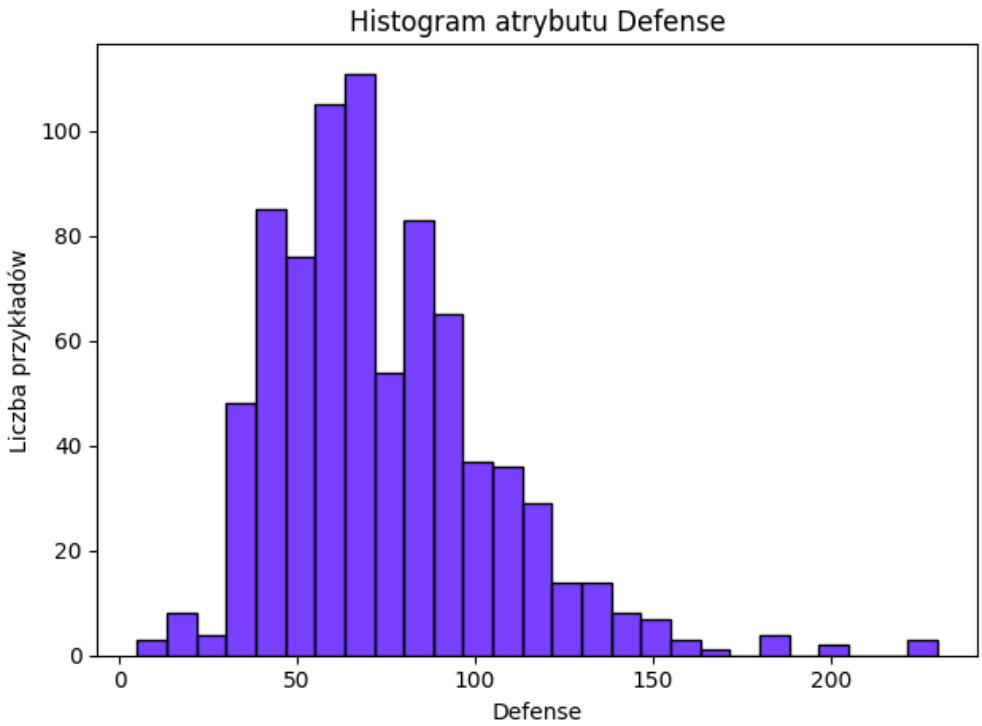

Atrybut	Wykres
Sp. Atk	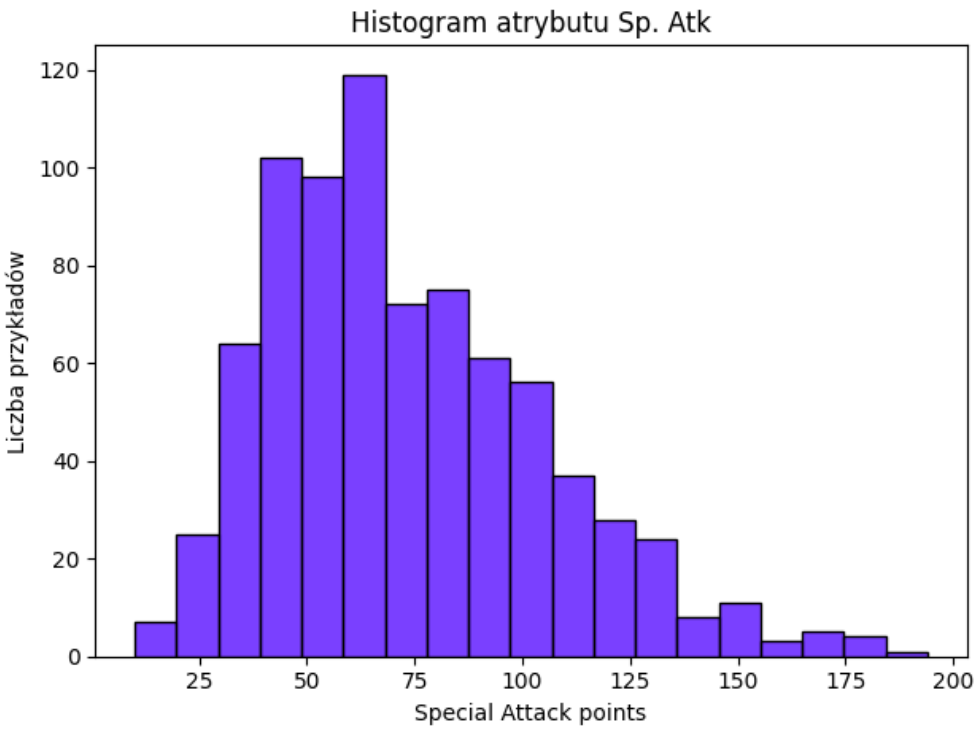
Sp. Def	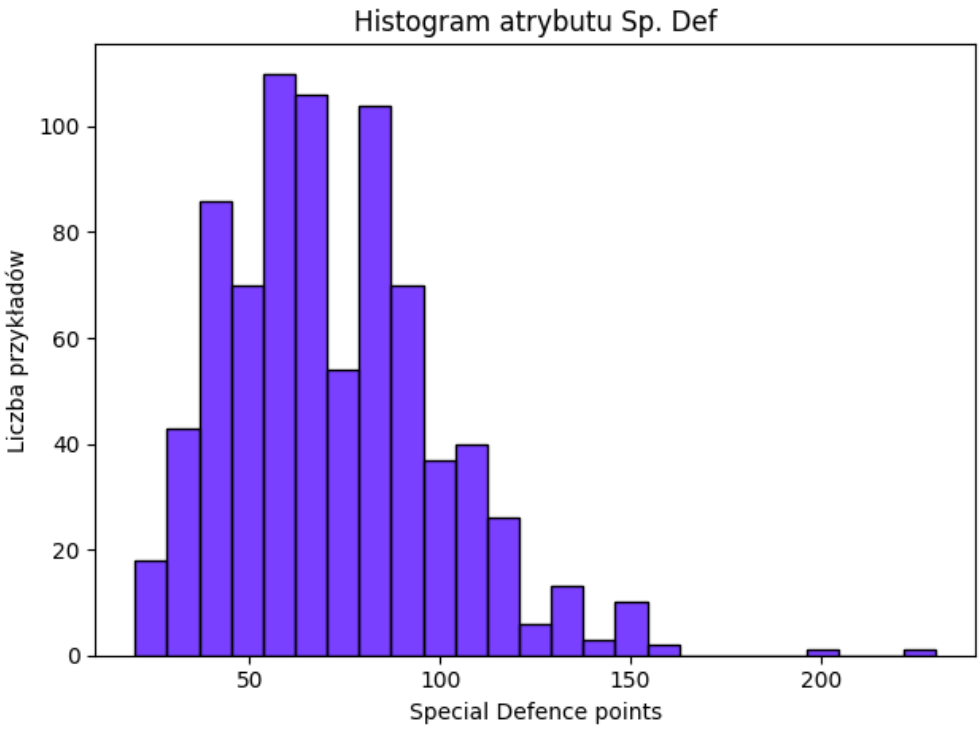

Atrybut	Wykres
Speed	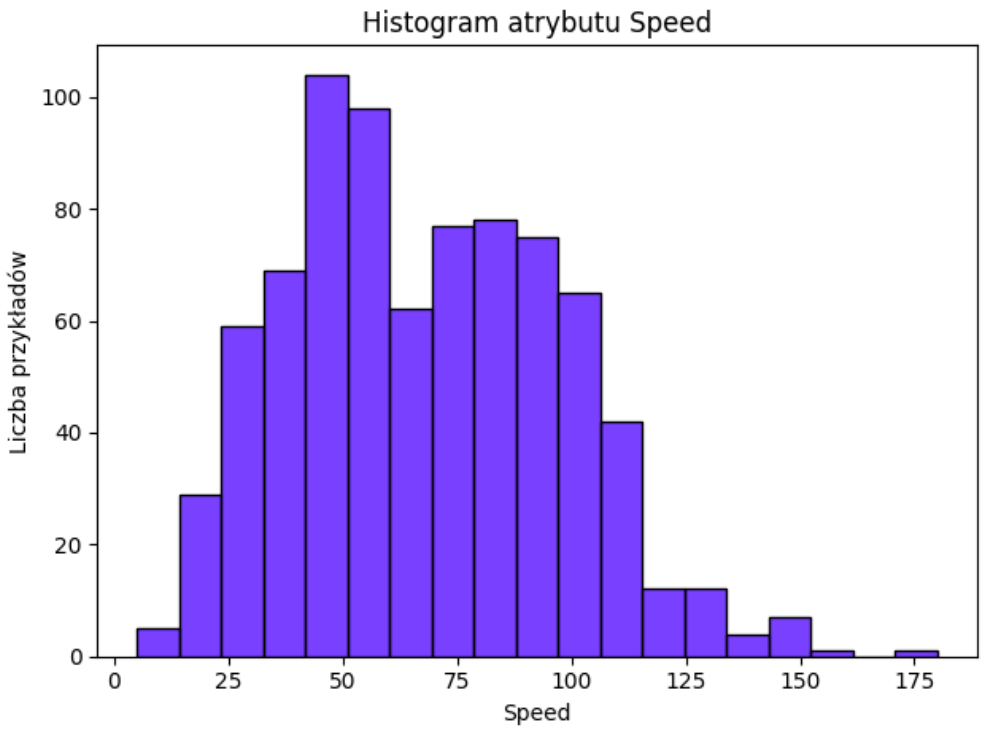

Wnioski dotyczące rozkładów wartości atrybutów

- Atrybut `Legendary` jest silnie niezbalansowany — tylko 65 spośród 800 pokemonów (8,1%) jest legendarnych. Może to mieć wpływ na dalsze modelowanie.
- Rozkład atrybutu `Generation` jest w dużym przybliżeniu równomierny — każda generacja ma podobną liczbę przynależących do niej pokemonów.
- Przynależność do wyższej generacji nie wydaje się mieć istotnego wpływu na rozkład statystyk pokemonów — rozkłady statystyk nie wykazują przesunięcia w kierunku wyższych wartości ani zwiększonej liczby obserwacji ekstremalnych.
- Atrybuty `Type 1` i `Type 2` przyjmują po 18 unikalnych wartości (nie wliczając w to wartości brakujących). W przypadku `Type 1` najczęstszy jest typ Water (112 pokemonów), jednak różnice między typami nie są dramatyczne. Dla `Type 2` dominuje Flying (97 pokemonów), przy czym blisko połowa pokemonów nie ma przypisanego drugiego typu ataku.
- Rozkłady atrybutów numerycznych (HP, Attack, Defense, Sp. Atk, Sp. Def, Speed) są prawoskośne [ang. *positive skew*] — większość pokemonów ma niskie lub średnie wartości statystyk, natomiast nieliczne pokemony osiągają wartości ekstremalne, tworząc długi prawy ogon rozkładów.

Dodatkowe potwierdzenie prawoskośności rozkładów statystyk

Mimo iż skośność rozkładu atrybutów numerycznych można stosunkowo łatwo ocenić na podstawie histogramów, zdecydowaliśmy się potwierdzić te obserwacje za pomocą prostych miar statystycznych - porównania relacji między średnią ($\bar{x}$) i medianą (M) oraz skośności nieparametrycznej (S). Zastosowane przez nas metody nie należą do najbardziej precyzyjnych, jednak ze względu na ich intuicyjność oraz brak założeń dotyczących rozkładu danych, uznaliśmy je za wystarczające.

Pierwszą wykorzystaną metodą jest porównanie wartości Mediany i średniej poszczególnych atrybutów. W rozkładach prawoskośnych zazwyczaj zachodzi relacja $\bar{x} > M$ - tj. średnia powinna być większa od mediany.

Drugą wykorzystaną metodą jest skośność nieparametryczna (S). Metoda ta nie zawsze zgadza się z przyjmowaną dzisiaj definicją skośności, ale jest wystarczająco zbliżona dla naszych potrzeb. Dla rozkładów prawoskośnych miara ta powinna przyjmować wartości dodatnie (> 0). Do jej obliczenia potrzebujemy średniej ($\bar{x}$), mediany (M) i odchylenia standardowego (σ) i wykorzystujemy wzór [7]:

$$S = \frac{\bar{x} - M}{\sigma}$$

W tabeli 3.3 poniżej zebraliśmy wyniki opisanych powyżej testów dla atrybutów numerycznych zbioru `pokemon`. Wyniki te wyraźnie potwierdzają zaobserwowaną na wykresach prawoskośność wszystkich badanych rozkładów - średnia wartość każdego atrybutu jest większa od wartości jego mediany, a wszystkie obliczone skośności nieparametryczne są dodatnie.

Tabela. 3.3: Weryfikacja prawoskośności rozkładów statystyk

Atrybut	$\bar{\mathbf{x}}$	**M**	σ	$\bar{\mathbf{x}}$? **M**	**S**
HP	69.26	65.00	25.53	$>$	0.1668
Attack	79.00	75.00	32.46	$>$	0.1233
Defense	73.84	70.00	31.18	$>$	0.1232
Sp. Atk	72.82	65.00	32.72	$>$	0.2390
Sp. Def	71.90	70.00	27.83	$>$	0.0684
Speed	68.28	65.00	29.06	$>$	0.1128

Korelacja pomiędzy wartościami atrybutów

W celu zbadania, które statystyki mają największy wpływ na wynik walk, obliczono macierz korelacji (Pearsona) pomiędzy atrybutami numerycznymi zbioru `pokemon` a współczynnikiem zwycięstw (*Win Rate*) wyznaczonym na podstawie zbioru `combats`. *Win Rate* definiowany jest jako stosunek liczby wygranych walk przez danego pokemona do całkowitej liczby pojedynków, w których brał on udział. W analizie tej pominięto atrybuty typów (`Type 1`, `Type 2`), ponieważ są to dane nominalne, co uniemożliwia bezpośrednie obliczenie ich korelacji z innymi zmiennymi numerycznymi przy użyciu standardowych metod. Poniżej przedstawiono wyniki w formie macierzy korelacji oraz wykresu słupkowego.

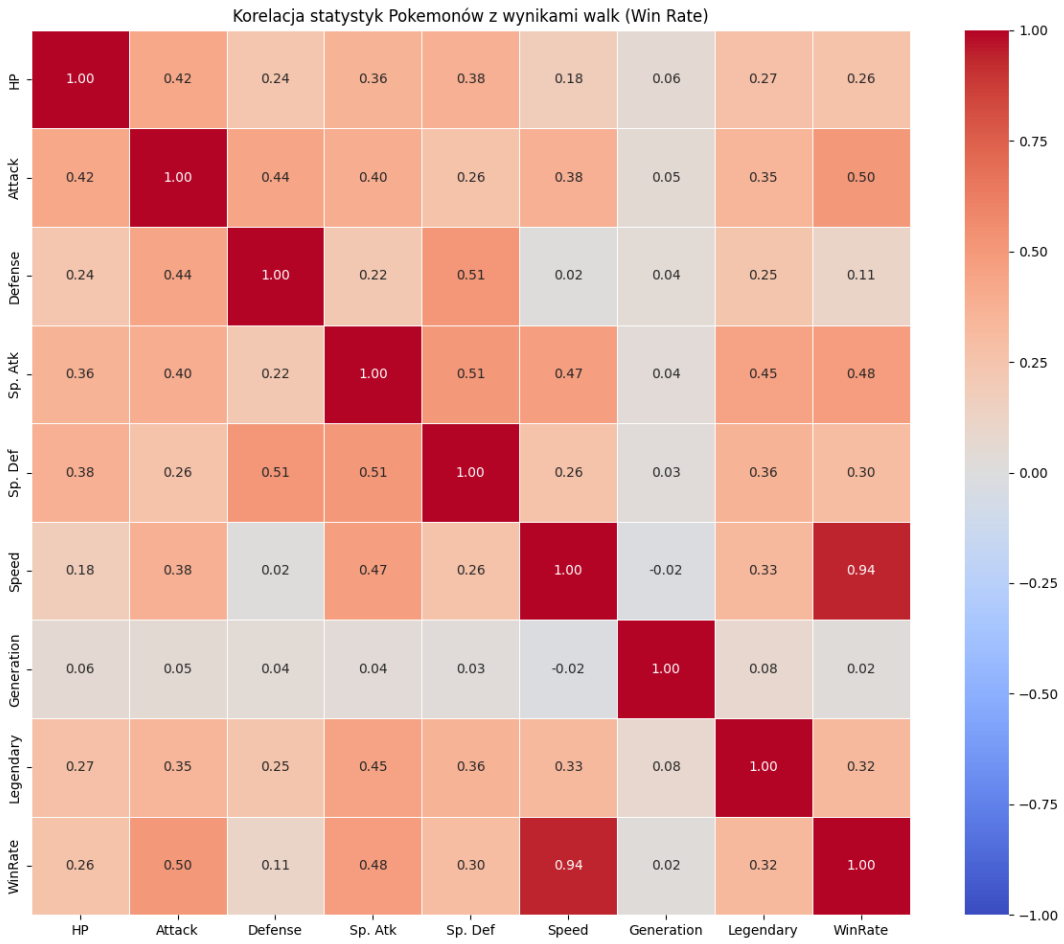

Rys 3.1: Macierz korelacji statystyk pokemonów ze współczynnikiem zwycięstw

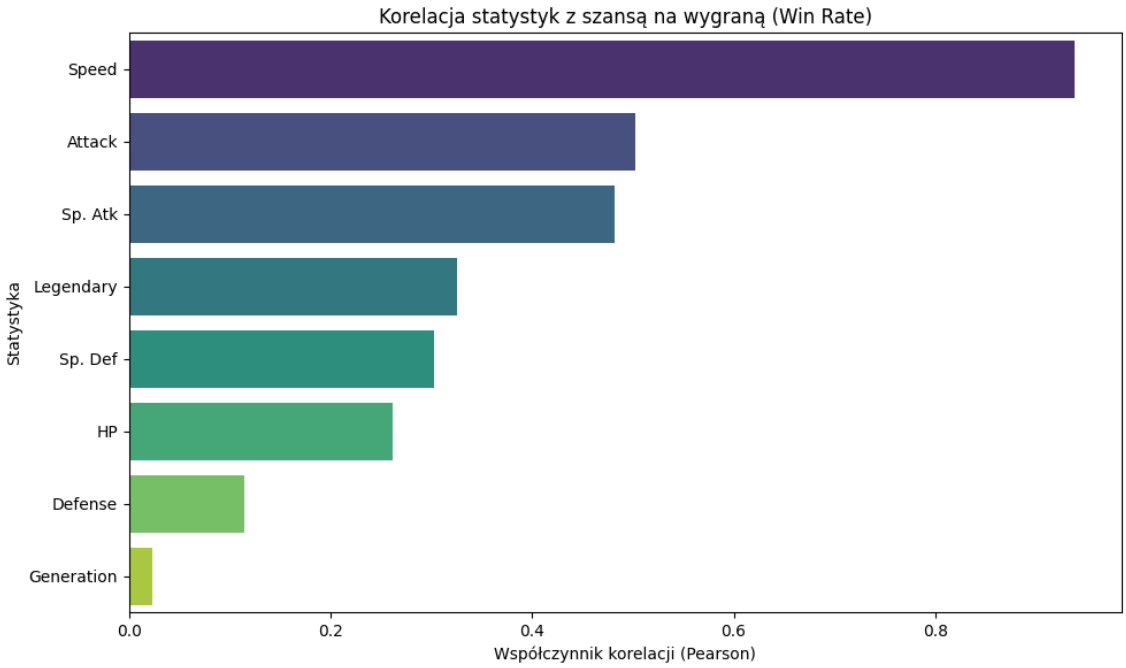

Rys 3.2: Korelacja poszczególnych statystyk ze współczynnikiem zwycięstw

Wnioski dotyczące korelacji

- Najsilniejszą korelację z *Win Rate* wykazuje atrybut `Speed` (wartość korelacji $\approx$ 0.94). Oznacza to, że szybkość pokemona jest decydującym czynnikiem wpływającym na wynik walki w tym zbiorze danych. Jest to zgodne z mechaniką gry, w której pokemon o wyższej prędkości atakuje jako pierwszy, co daje mu przewagę.

- Na kolejnych miejscach pod względem korelacji z *Win Rate* znalazły się: `Attack` ($\approx$ 0.50) oraz `Sp. Atk` ($\approx$ 0.48). Oba atrybuty bezpośrednio wpływają na zadawane obrażenia, co tłumaczy ich istotny związek z wynikiem walki.

- Atrybut `Legendary` wykazuje korelację $\approx$ 0.32 z *Win Rate*. Pokémony legendarne mają generalnie wyższe statystyki, stąd ich wyższa skuteczność w walkach.

- Atrybuty `Defense` ($\approx$ 0.11) i `Generation` ($\approx$ 0.02) mają najniższą korelację z *Win Rate*, co sugeruje, że obrona i generacja pokemona mają stosunkowo małe znaczenie dla predykcji wyniku walki w tym zbiorze.

- Macierz korelacji między samymi statystykami wskazuje na umiarkowane związki pomiędzy `Defense` i `Sp. Def` ($\approx$ 0.51) oraz pomiędzy `Sp. Atk` i `Sp. Def` ($\approx$ 0.51), co może świadczyć o pewnej redundancji tych atrybutów.

Analiza zmiennych kategorycznych w podziale na generacje

W ramach eksploracyjnej analizy danych zbadaliśmy również, czy istnieje zależność pomiędzy generacją pokemona a jego typem. Głównym celem tej analizy było sprawdzenie, czy dane te są zgodne z mechaniką prawdziwej gry (konkretne typy pojawiają się dopiero w konkretnych generacjach).

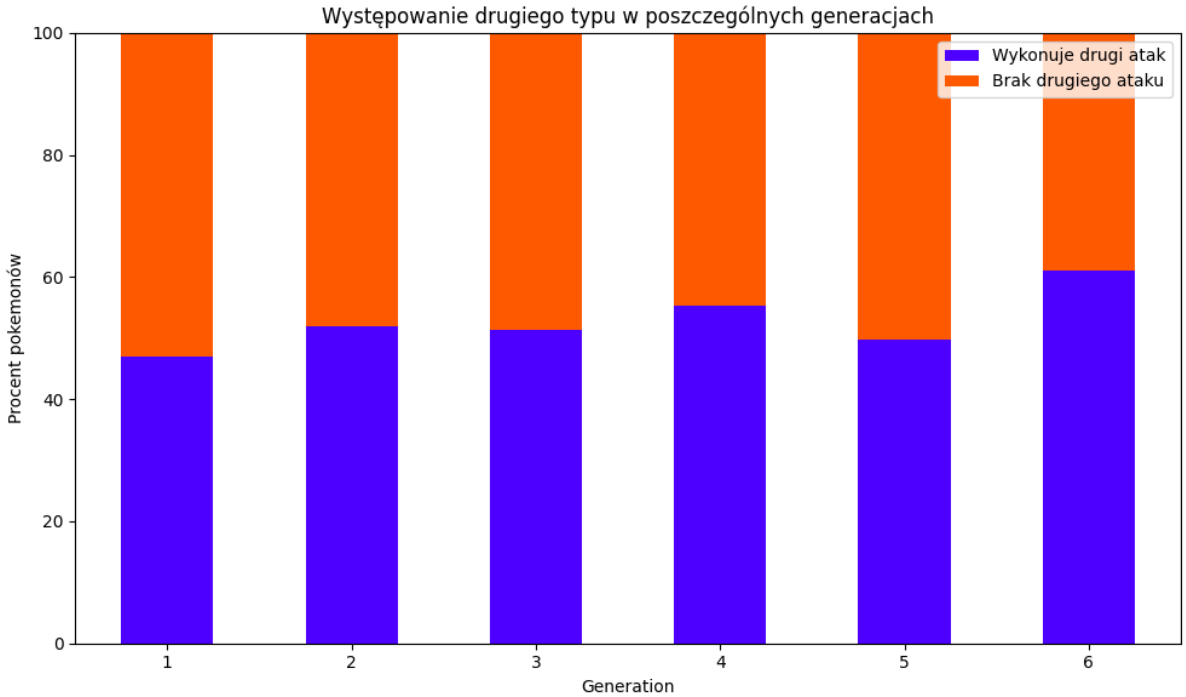

Rys 3.3: Wykres reprezentujący udział procentowy pokemonów wykonujących drugi atak

Wykres 3.3 znajdujący się na poprzedniej stronie wyraźnie pokazuje, że przynależność pokemona to konkretnej generacji nie ma znacznego wpływu na to, czy będzie on miał drugi typ. Dodatkowo wykres pokazuje nam, że rozkład pokemonów względem możliwości wykonywania ataków jest mniej więcej równomierny i bliski 50% dla każdej z generacji.

Wykres 3.4 poniżej, obrazuje jaki procent pokemonów danego typu przynależy do danej generacji (np. 58% pokemonów typu Poison jest w pierwszej generacji). Możemy jasno zaobserwować, że podział typów pokemonów nie jest zgodny z mechaniką prawdziwej gry - wszystkie typy występują w każdej z generacji (nawet jeśli jest to niewielka ilość).

Możemy też zauważyć, że rozkład typów (za wyjątkiem typu Poison) jest w miarę równomierny - typy nie koncentrują się w wybranych generacjach.

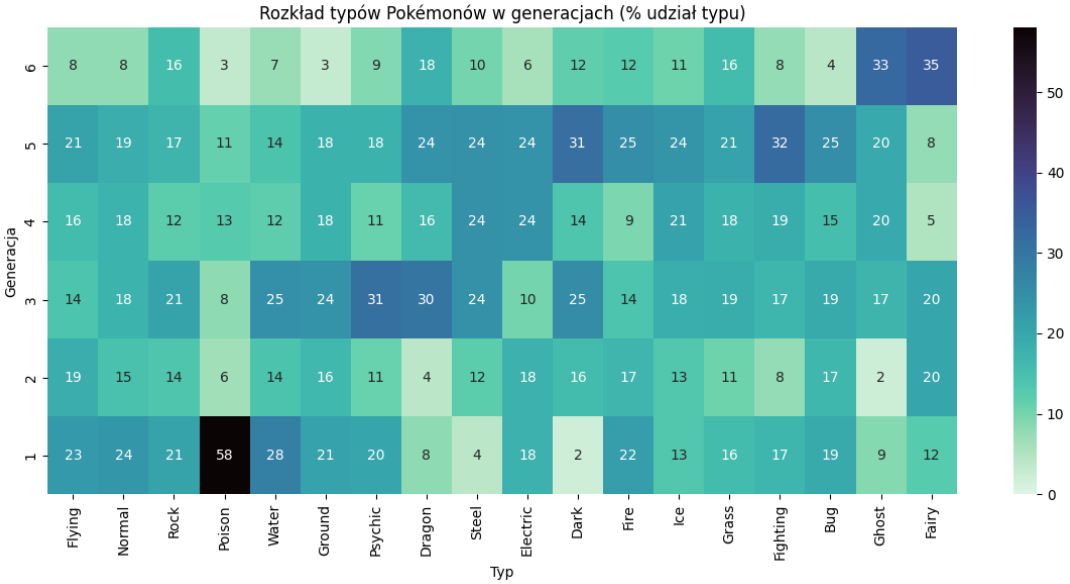

Rys 3.4: Wykres reprezentujący procentowy udział typów pokemonów w zależności od generacji

3.3. Wyniki analizy danych a cel eksploracji

Na podstawie przeprowadzonej analizy eksploracyjnej można ocenić, że ustalony przez nas cel eksploracji jest możliwy do osiągnięcia.

Atrybut `Speed` dominuje jako predyktor wyniku walki, ale pozostałe atrybuty ofensywne (Attack, Sp. Atk) również wnoszą istotną informację. Dane są dobrej jakości — brak brakujących wartości w atrybutach numerycznych, jedynie atrybut `Type 2` wymaga obsługi wartości pustych. Punkty oddalone nie stanowią błędów i zostają zachowane, gdyż odzwierciedlają charakterystykę silniejszych pokemonów.

4. Podsumowanie

Przeprowadzona eksploracyjna analiza danych pozwoliła nam na wstępną ocenę jakości zbioru danych oraz identyfikację najważniejszych zależności między statystykami pokemonów a wynikami ich walk.

4.1. Najważniejsze obserwacje

- Dane są spójne i zrozumiałe. Dane brakujące (atrybut `Type 2`) oraz punkty oddalone (najwięcej dla HP: 2,4%) mają uzasadnienie merytoryczne i nie stanowią błędów pomiarowych. Ich pozostawienie jest kluczowe dla zachowania zdolności predykcyjnych modelu w starciach z najsilniejszymi jednostkami.

- Analiza korelacji wskazała atrybut `Speed` jako najsilniejszy predyktor wyniku walki (korelacja ≈ 0.94). Atrybuty ofensywne (`Attack`, `Sp. Atk`) również wykazują istotny związek z wygraną. Jednocześnie największa korelacja między samymi statystykami wynosi ok. 0.51 — ze względu na umiarkowaną siłę tych powiązań nie zaleca się redukcji wymiarowości, aby nie utracić cennych informacji.

- Mimo niezbalansowania niektórych atrybutów nominalnych (np. tylko 8,1% to pokemony `Legendary`), sama zmienna celu jest dobrze zbalansowana — zwycięstwa pierwszego pokemona stanowią 47,20%, a drugiego 52,80%. Ułatwi to proces trenowania modelu bez konieczności stosowania technik re-samplingu.

- Analiza statystyczna atrybutów numerycznych (HP, Attack, Defense, Sp. Atk, Sp. Def, Speed) wykazała, że dla każdego z nich średnia arytmetyczna jest większa od mediany ($\bar{x} > M$), a współczynnik skośności nieparametrycznej S przyjmuje wartości dodatnie. Dowodzi to wyraźnej prawoskośności rozkładów — większość pokemonów posiada przeciętne statystyki, a nieliczne jednostki o ekstremalnych wartościach (w tym pokemony legendarne) tworzą tzw. "długi ogon"rozkładu.

4.2. Wnioski końcowe

Biorąc pod uwagę wysoką jakość danych oraz silne zależności korelacyjne między statystykami (szczególnie szybkością i atakiem) a wynikami historycznych walk, uznajemy, że cel eksploracji — budowa modelu klasyfikacji binarnej o wysokiej dokładności — jest w pełni osiągalny. Zbiór danych jest wystarczający i kompletny, co pozwala na przejście do kolejnego etapu projektu (przygotowanie danych i modelowanie) bez konieczności rewizji pierwotnych celów i kryteriów sukcesu.

Wykaz Literatury

[1] Witten I.H., Frank E., Hall M.A.: Input: Concepts, Instances, and Attributes, W: *Data Mining. Practical Machine Learning Tools and Techniques*, Wydanie III, Burlington, USA: Morgan Kaufmann (Elsevier), 2011, s.39-60, ISBN 978-0-12-374856-0.

[2] Waloszek W., Zawadzka T.: *Podstawowe Zagadnienia i Terminy* [materiały wykładowe], Gdańsk (Politechnika Gdańska), 2026

[3] Waloszek W., Zawadzka T.: *Eksploracyjna Analiza Danych (EDA)* [materiały wykładowe], Gdańsk (Politechnika Gdańska), 2026

[4] Accuracy and precision, W: *Wikipedia*, [online], 18.04.2026, [przeglądany 19.04.2026], Dostępny w: `https://en.wikipedia.org/wiki/Accuracy_and_precision`

[5] F-score, W: *Wikipedia*, [online], 22.03.2026, [przeglądany 19.04.2026], Dostępny w: `https://en.wikipedia.org/wiki/F-score`

[6] Precision and recall, W: *Wikipedia*, [online], 22.03.2026, [przeglądany 19.04.2026], Dostępny w: `https://en.wikipedia.org/wiki/Precision_and_recall`

[7] Nonparametric skew, W: *Wikipedia*, [online], 18.02.2026, [przeglądany 19.04.2026], Dostępny w: `https://en.wikipedia.org/wiki/Nonparametric_skew`

[8] Skewness, W: *Wikipedia*, [online], 11.03.2026, [przeglądany 19.04.2026], Dostępny w: `https://en.wikipedia.org/wiki/Skewness`