EKSPLORACJA DANYCH

Etap 1: Zrozumienie danych i problemu

Alicja Sobiech, 188861
Nikolai Lavrinov, 201302
Maciej Łukasiewicz, 197865

ZBIÓR DANYCH

Pokemon- Weedle's Cave

ZAWARTE ZBIORY DANYCH

- **combats** - rozstrzygnięte walki (50 000 przykładów)
- **pokemon** - pokemony (800 przykładów)
- **tests** - zbiór testowy (10 000 przykładów)

ATRYBUTY

Zbiór **combats**

- Numery ID pokemonów (2)
- Numer ID zwycięskiego pokemona

Zbiór **tests**

- Numery ID pokemonów (2)

Zbiór **pokemon**

- Numer ID
- Nazwa pokemona
- Typy ataków (2)
- Statystyki numeryczne (6)
- Generacja
- Status *Legendary*

CEL EKSPLORACJI

Celem eksploracji jest budowa modelu pozwalającego na p**redykcję wyników walk pokemonów** na podstawie przypisanym im statystyk.

Dodatkowym celem jest określenie, które **statystyki mają największy wpływ na rezultat** pojedynków.

WYKORZYSTYWANE METRYKI

Dokładność - informuje nas o tym, jak dobrze nasz model klasyfikuje walki, bez względu na ich wynik.

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN}$$

F1-score - pozwala ona na bardziej zrównoważoną ocenę modelu

$$F_1 = \frac{2}{\text{recall}^{-1} + \text{precision}^{-1}} = 2\frac{\text{precision} \cdot \text{recall}}{\text{precision} + \text{recall}} = \frac{2TP}{2TP + FP + FN}$$

KRYTERIA SUKCESU

Dokładność o wartości minimum **80%**

F1-score o wartości minimum **0.75**

JAKOŚĆ DANYCH

- **Dane brakujące** - prawie połowa atrybutu ‘Type 2’
- **Dane niespójne** - dane są spójne w ramach pojedynczego zbioru i pomiędzy zbiorami
- **Dane niezrozumiałe** - dane są zrozumiałe intuicyjnie, chociaż znajomość gry jest pomocna
- **Punkty oddalone** - niewiele punktów oddalonych

ROZKŁADY WARTOŚCI ATRYBUTÓW

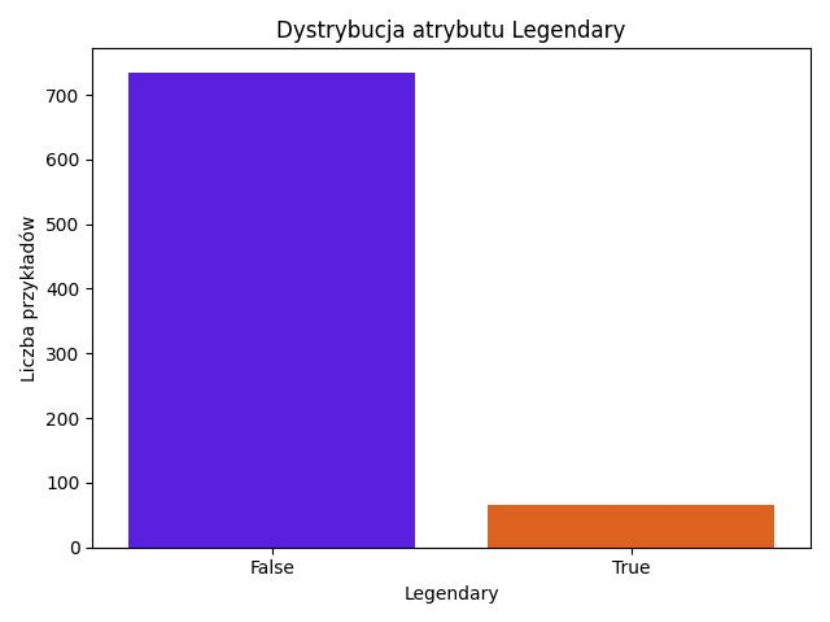

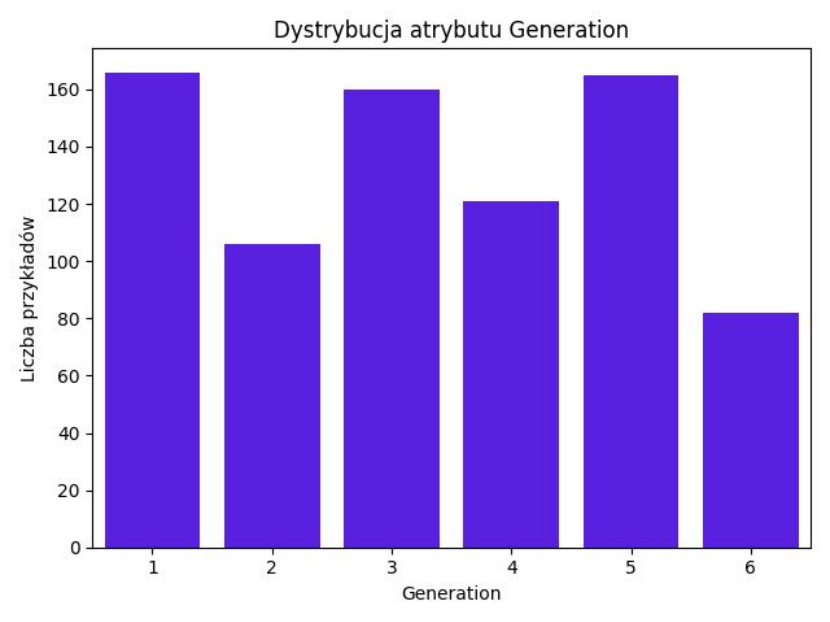

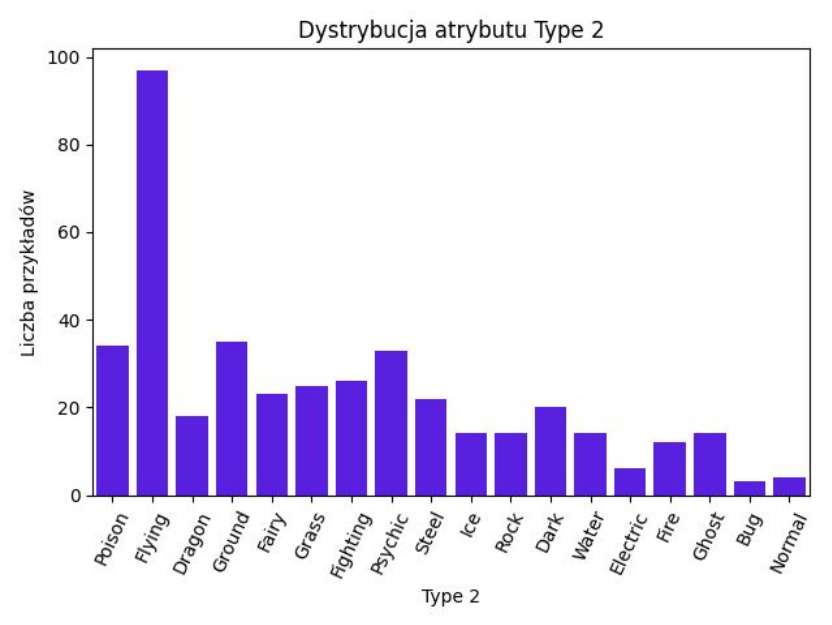
Dystrybucja atrybutu Type 2
Liczba przykładów
0
20
40
60
80
100
Poison
Flying
Dragon
Ground
Fairy
Grass
Fighting
Psychic
Steel
Ice
Rock
Dark
Water
Electric
Fire
Ghost
Bug
Normal
Type 2

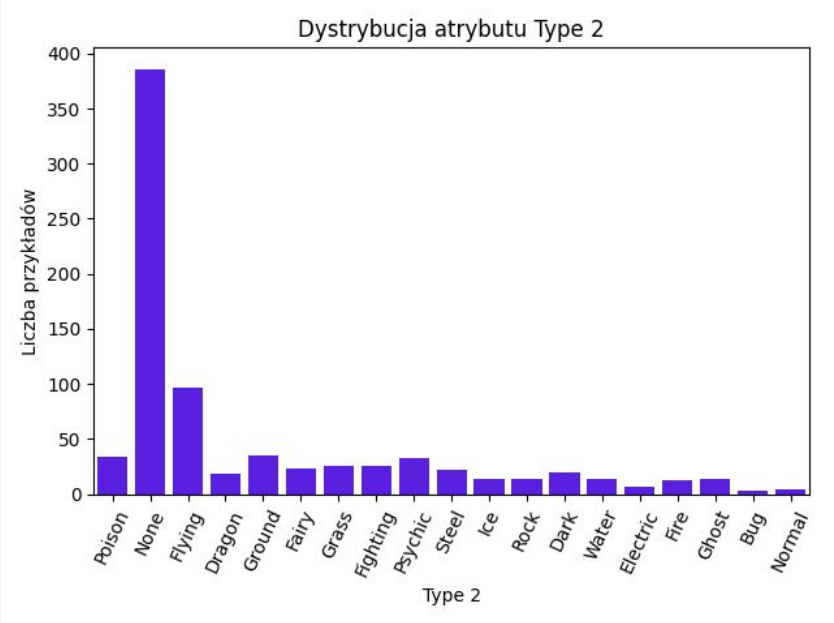
Dystrybucja atrybutu Type 2
Liczba przykładów
0
50
100
150
200
250
300
350
400
Poison
None
Flying
Dragon
Ground
Fairy
Grass
Fighting
Psychic
Steel
Ice
Rock
Dark
Water
Electric
Fire
Ghost
Bug
Normal
Type 2

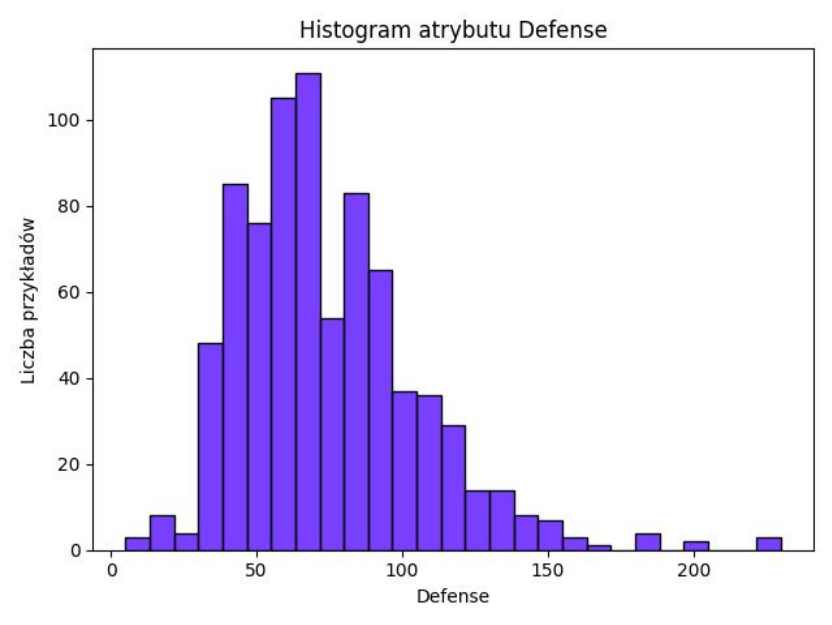
Histogram atrybutu Defense
Liczba przykładów
Defense
0
20
40
60
80
100
0
50
100
150
200

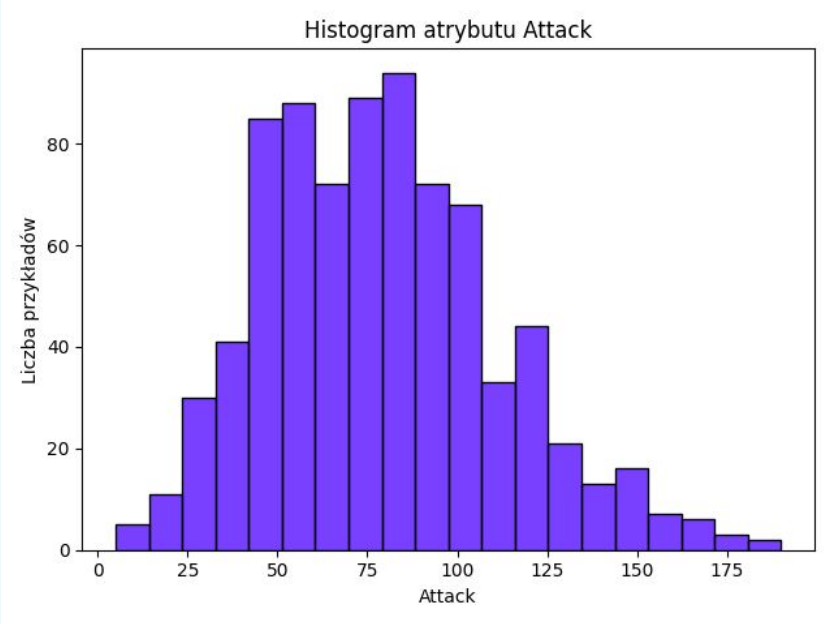
Histogram atrybutu Attack
Liczba przykładów
Attack
0
20
40
60
80
0
25
50
75
100
125
150
175

POTWIERDZENIE PRAWOSKOŚNOŚCI ROZKŁADÓW

Porównanie relacji między medianą i średnią

$$\bar{x} > M$$

Skośność nieparametryczna

$$S = \frac{\bar{x} - M}{\sigma}$$

KORELACJA MIĘDZY WARTOŚCIAMI ATRYBUTÓW

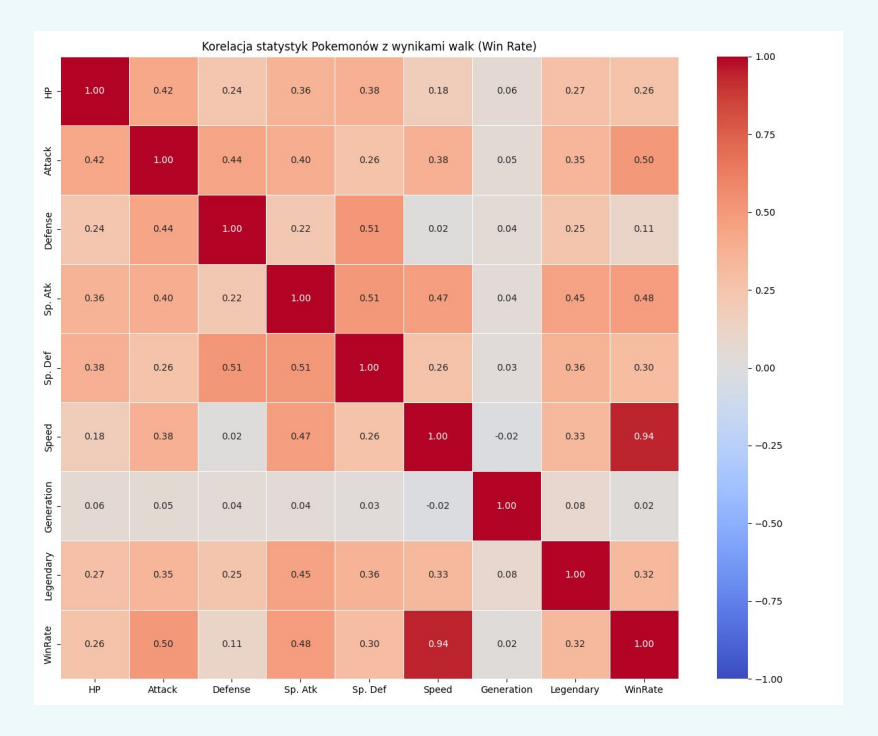

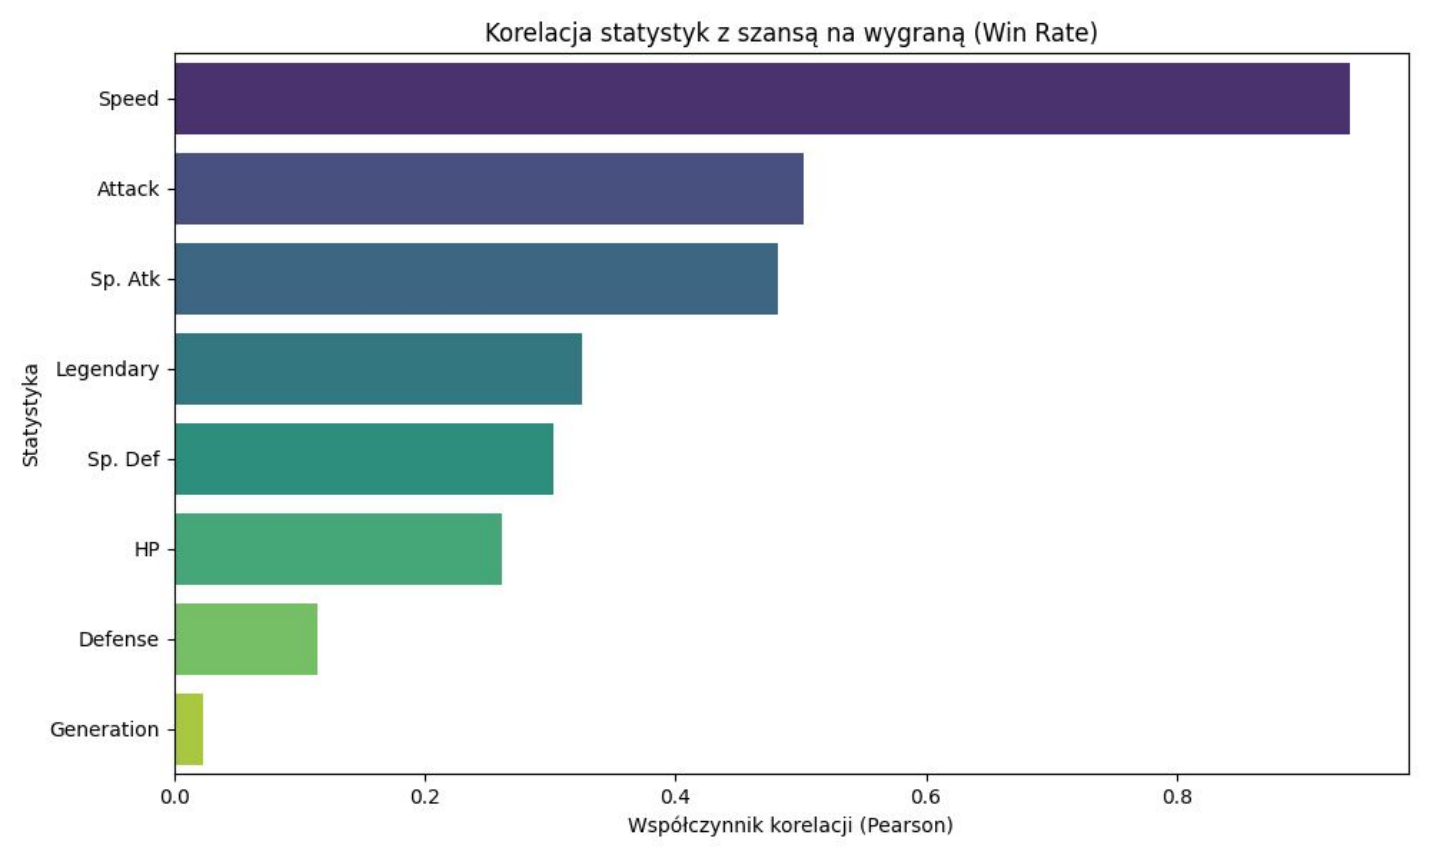
Korelacja statystyk z szansą na wygraną (Win Rate)
Speed
Attack
Sp. Atk
Legendary
Sp. Def
HP
Defense
Generation
Statystyka
0.0
0.2
0.4
0.6
0.8
Współczynnik korelacji (Pearson)

TYPY POKEMONÓW A GENERACJE

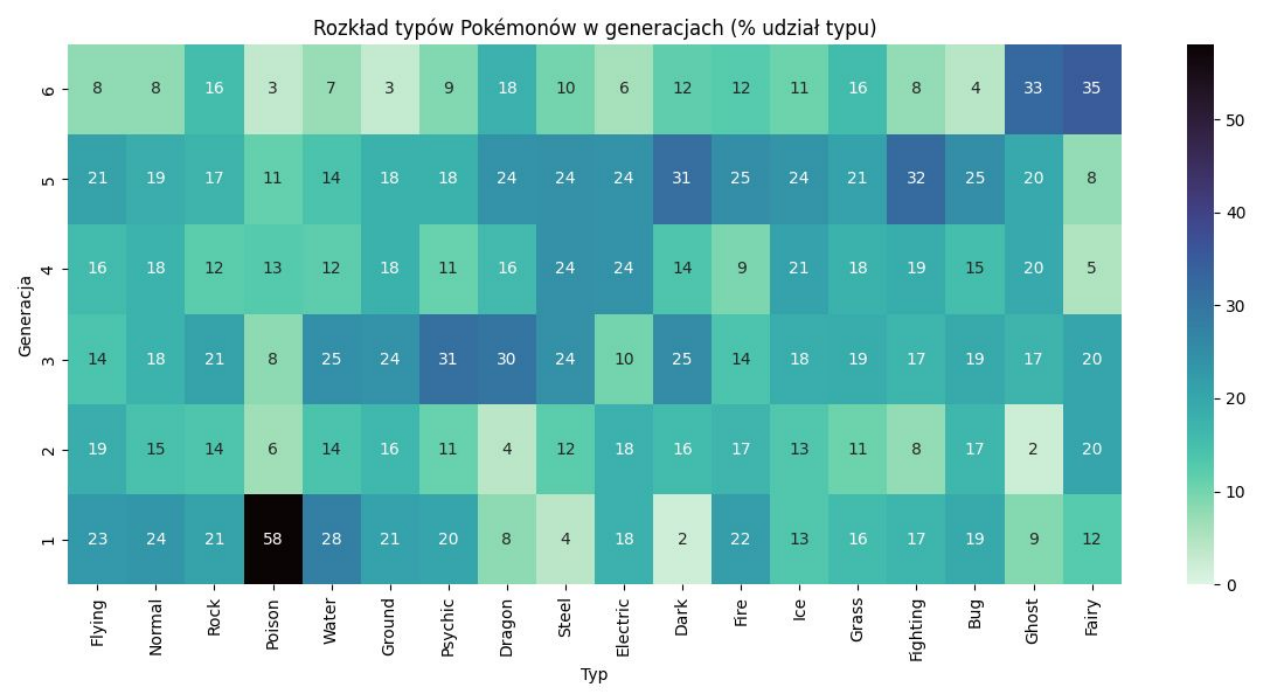

WYNIKI ANALIZY A CEL EKSPLORACJI

Na podstawie przeprowadzonej analizy eksploracyjnej można ocenić, że ustalony przez nas **cel eksploracji jest możliwy do osiągnięcia.**